

GROUNDEDHUMAN: METRIC 4D HUMAN-SCENE RECONSTRUCTION WITH GEOMETRIC INTERACTION LEARNING

Anonymous authors

Paper under double-blind review




图 1: 核心观察示意。通用场景模型能够从单目视频恢复结构一致的相对场景和相机轨迹, 但其全局尺度仍可能未定。具有规范物理尺寸的 SMPL 人体为视频提供内生度量参照, 使相对深度、相机平移和人体世界轨迹能够进入同一尺度一致坐标。该图为概念示意, 不表示定量实验结果。

摘要

我们提出 **GroundedHuman**, 一种从随手拍摄的单目视频中恢复尺度一致四维人体-场景世界的几何交互学习框架。现有方法已经能够联合预测场景、相机与人体, 但联合输出并不天然意味着度量一致: 场景基础模型恢复的相对几何与参数化人体所携带的米制尺度仍可能处于不同的坐标规范, 进而破坏相机轨迹、人体世界运动及人物-环境关系。我们的核心观点是, 人体不应仅被视为场景中的动态重建目标, 还应作为连接场景几何、相机运动与人体轨迹的内生度量锚点。基于这一观点, **GroundedHuman** 构建人体尺度桥, 由可见人体表面建立稳健的场景尺度共识, 并以人物条件的残差校准将同一米制规范一致传播到场景深度和相机平移。在此基础上, 我们进一步提出 **TRSTR**, 从规范人体区域及其周围环境中提取局部几何交互证据, 以受约束且置信感知的迭代更新精校人体世界位置, 同时严格保持已有的局部姿态与形状。由此, **GroundedHuman** 将相对场景、相机轨迹和多人运动统一到同一个具有物理意义的四维世界中。广泛实验表明, 该框架在保持强局部人体恢复能力的同时, 显著提升世界坐标人体运动, 并在相机轨迹与视频深度评测中展现出稳定的度量重建能力。结果验证了本文的中心主张: 场景中的人体是一种强大而通用的几何先验, 能够为缺少可靠绝对尺度的视觉重建建立共享的米制坐标规范。

1 引言

从随手拍摄的单目视频中恢复动态三维世界, 是具身智能、增强现实、机器人感知和人类行为理解的重要基础。完整的世界建模不仅需要重建静态环境, 还需要恢复相机运动以及场景中一个或多个人的姿态与轨迹, 并将这些输出表达在同一个世界坐标中 (Chen et al., 2026; Li et al., 2026; Liu et al., 2026)。这一要求看似只是组合场景重建与人体网格恢复, 实际却引入了更严格的度量约束: 场景深度、相机平移和人体位置必须共享物理尺度, 否则局部上合理的几何仍会产生错误的相机基线、人体世界轨迹和人物-环境关系。

学习式三维重建与人体网格恢复已经分别取得了快速进展。DUST3R、MASt3R 及其动态扩展通过像素对齐 pointmaps 建立跨视图三维对应 (Wang et al., 2024a; Leroy et al., 2024; Zhang et al., 2024), CUT3R、VGGT、 π^3 和 VGGT- Ω 进一步增强了多视图或视频中的场景与相机推理 (Wang et al., 2025b;a;c; 2026a)。与之并行, 基于 SMPL/SMPL-X 的 HMR 模型已从复杂图像和视频恢复稳定的局部人体, TRAM、WHAM、GVHMR 和 DuoMo 等工作则将人体提升到世界坐标 (Wang et al., 2024b; Shin et al., 2024; Shen et al., 2024; Wang et al., 2026b)。这些进展提供了高质量场景结构和人体先验, 却没有自动保证两类输出处于相同的米制 gauge: 相对深度与相机平移可以共同缩放而保持投影不变, 人体世界运动则会直接继承这一未定尺度。

近期联合人体-场景方法开始显式连接两类先验。JOSH 通过测试时联合优化相机、场景、人体和接触约束获得几何一致的重建, JOSH3R 将其结果蒸馏为学习式预测 (Liu et al., 2026); Human3R 和 UniSH 分别通过 human prompts 或 AlignNet 联合读出场景、相机与人体 (Chen et al., 2026; Li et al., 2026); UniCon3R 进一步把接触作为网络内部的纠正信号 (Sur et al., 2026)。这些方法主要从联合表示、接触或人体放置角度改善一致性。与本文最接近的 MetricHMSR 使用米制人体引导单图逐像素深度仿射, GRAFT 则在外部米制场景中以局部几何 probes 迭代更新人体姿态、形状、平移和尺度 (Song et al., 2026; Pradyumna YM et al., 2026)。然而, 如何以视频中的米制人体直接固定相对场景及相机的尺度规范, 并在不改变局部人体姿态的条件下进一步修正世界位置, 仍缺少明确的建模分解。

本文的出发点十分直接: 人体不仅是待重建的动态目标, 也是场景中少数具有可预测物理尺寸的对象。NLF 输出的 SMPL 网格已经以米表示 (Sárándi & Pons-Moll, 2024; Loper et al., 2023); 当人体投影、场景深度和相机内参对应同一图像平面时, 可见人体表面的 Z-depth 与同像素相对深度之比便形成尺度约束。真正的困难在于, 这一约束并非处处可靠。人体初始误差、自遮挡、其他人物遮挡、深度边界和局部场景噪声都会产生重尾比例与错误对应。因此, 人体尺度不能被简化为单一关节或单点深度的直接比值, 而需要在可见表面、多人物证据和视频尺度一致性之间建立受约束的鲁棒估计。

基于这一观察, 我们提出一个由解析规范化和学习式残差组成的人体尺度桥。首先, 将置信人体的 SMPL 表面投影到 VGGT- Ω 相对深度图, 并以 z-buffer 式前表面筛选消除同像素的遮挡冲突; 所有有效表面比值的中位数给出解析粗尺度, 从而移除场景的主尺度自由度。随后, 以 24 个身体 anchors 为人体-场景交互 tokens, 查询局部深度残差和 VGGT- Ω 多层场景特征, 预测接近恒等映射的 residual scale 与 depth bias。对于世界坐标重建, 解析尺度与残差尺度在 clip 内共同聚合, 并将同一个共享尺度应用于深度和相机平移。该分解使解析几何负责尺度数量级, 学习模块只建模遮挡、投影和深度偏差留下的局部残差。

场景米制化并不意味着人体位置已经与局部环境完全一致。为此, 我们进一步提出区域化平移精校模块 TRSTR。该模块把 SMPL 表面组织为 96 个具有稳定解剖对应的区域, 并在每个区域周围分别探测 self-surface、environment 和 other-human 几何。区域在相机 ray/tangent 基底中提出有界平移 vote, 再通过 region gate、预测不确定性和 person gate 聚合为共享根部更新。每轮更新后重新投影人体并重新采集场景证据, 形成两轮几何闭环。与联合更新完整人体参数的方法不同, TRSTR 将优化空间严格限制为 camera-space translation, 因而不会通过改变 pose 或 shape 换取世界坐标误差的下降。

我们在局部人体、世界运动、相机轨迹和米制深度四个维度评估这一设计。在 3DPW 上, 本文保持 NLF 的 37.3 mm PA-MPJPE、60.3 mm MPJPE 和 71.4 mm PVE, 说明尺度与平移校准没有损害局部人体。EMDB-2 上, 本文取得 58.468 mm WA-MPJPE、149.959 mm W-MPJPE 和 1.079% RTE, 表明主要收益来自尺度一致的相机到世界变换和根部轨迹。TUM-Dynamic 上, VGGT- Ω 在 500 个输入视图处保持 0.00692 m ATE, 为长序列相机轨迹提供稳定基础。Bonn 上, 人体尺度校准在不使用 GT scale 或 shift 的情况下取得 0.08599 Abs Rel 和 0.96377 的 $\delta < 1.25$, 进一步验证人体能够把稳定相对结构转换为有效米制深度。

本文的贡献概括如下:

- 提出一种人体锚定的尺度规范化框架, 将具有米制含义的 SMPL 表面转化为相对场景的内生度量参照, 并把恢复的共享尺度一致地传播到场景深度与相机平移。
- 设计由可见前表面解析尺度、人物条件 residual affine 和 TRSTR 组成的 coarse-to-fine 几何校准过程; TRSTR 通过规范解剖区域和异方差局部投票只修正人体根部平移, 保持局部姿态与形状不变。

- 在 3DPW、EMDB-2、TUM-Dynamic 和 Bonn 上从局部人体、世界运动、相机轨迹与场景深度四个方面建立实验链，验证环境中的人体能够为无可靠绝对尺度的场景重建提供有效米制锚点。

2 相关工作

2.1 学习式三维与四维场景重建

经典 Structure-from-Motion 系统以特征匹配、三角化和 bundle adjustment 为核心，在静态场景中能够恢复精确的稀疏几何与相机轨迹，COLMAP 是最具代表性的系统 (Schönberger & Frahm, 2016)。近年来，学习式重建逐步将对应估计、几何恢复和相机求解整合到统一网络中。DUST3R 以像素对齐 pointmap 连接图像对之间的三维关系 (Wang et al., 2024a)，MASt3R 在此基础上增加稠密描述子以强化跨视图匹配 (Leroy et al., 2024)。随后，MonST3R 将 pointmap 重建扩展到动态视频 (Zhang et al., 2024)，CUT3R 通过持续状态支持增量式四维重建 (Wang et al., 2025b)，VGGT 与 π^3 则进一步突破图像对范式，展示了全局多视图推理能力 (Wang et al., 2025a,c)。

这些模型提高了非标定图像和动态视频中的场景覆盖率，并使相机、深度与场景特征能够由学习式推理共同产生。VGGT- Ω 延续这一方向，以相机 token、场景 registers 和稠密预测头恢复多视图相机参数与深度，同时暴露可被下游任务复用的场景表示 (Wang et al., 2026a)。然而，投影一致的几何仍可能保留一个全局尺度规范自由度；在没有可靠米制参照时，深度与相机平移可以共同缩放而不改变图像重投影。现有通用重建工作主要优化场景结构和跨视图一致性，并不专门研究视频中人体的规范物理尺寸如何约束这一尺度自由度。

本文以 VGGT- Ω 的相对场景和相机为结构基础，但研究目标不是提出新的通用场景重建 backbone。我们的关注点是将场景中已经存在的 SMPL 人体转化为内生度量锚点：人体前表面首先解析固定场景的主尺度，人物条件模块再估计 residual affine，最终尺度同时作用于深度与相机平移。该设置将通用几何恢复与人体驱动的米制规范化分离，使本文能够直接检验“无可靠绝对尺度的场景模型能否借助人体恢复统一米制坐标”这一问题。

2.2 世界坐标人体运动恢复

人体网格恢复长期以相机坐标中的姿态和形状为主要目标。基于 SMPL/SMPL-X 的优化方法通过二维关键点和轮廓拟合人体参数 (Loper et al., 2023; Pavlakos et al., 2019)，学习式 HMR 则直接从单帧或视频特征回归局部人体 (Chen et al., 2026; Song et al., 2026)。局部 HMR 已能在复杂姿态和遮挡下提供较强的人体先验，但相机坐标中的人体并不能直接给出世界轨迹：单目视频同时混合了相机运动、人体运动和深度尺度，任何一个分量的系统误差都会在相机到世界的变换中累积 (Wang et al., 2026b)。

现有世界坐标人体恢复大致沿两条路线发展。一类方法首先估计相机空间人体，再利用 SLAM、相机轨迹、重力方向或外部米制深度将人体提升到世界坐标。GLAMR 使用运动先验补全遮挡并恢复全局轨迹 (Yuan et al., 2022)，TRAM 通过动态区域掩码和单目米制深度增强 SLAM 相机的尺度稳定性 (Wang et al., 2024b)，WHAM 与 GVHMR 进一步引入轨迹回归、重力和观察方向约束以改善世界运动 (Shin et al., 2024; Shen et al., 2024)。另一类方法直接学习世界空间人体分布。DuoMo 将问题分解为 camera-space 和 world-space 两个扩散阶段，并在每个视频自身的世界坐标中对提升后的运动提议进行生成式去噪 (Wang et al., 2026b)。

这些方法的主要输出是全局人体运动，场景几何通常作为相机估计、地面方向或后处理约束存在，而不是与人体共享的稠密重建目标 (Yuan et al., 2022; Wang et al., 2024b; Shin et al., 2024; Shen et al., 2024; Wang et al., 2026b)。本文不引入新的人体运动生成先验，也不重新估计 NLF 已经给出的局部姿态和形状。我们利用人体与场景之间的双向尺度关系：米制人体先约束相对场景，校准后的场景和相机随后又为人体根部平移提供局部几何参照。因而，世界人体精度的提升被限制在尺度和根部平移两个变量上，局部 HMR 路径保持不变。

2.3 联合人体-场景重建

联合人体-场景重建要求在同一坐标中恢复人体、相机和周围环境。早期方法通常组合场景重建、HMR、接触预测与运动先验，并在测试时联合优化多个变量。JOSH 从局部人体、深度、点对应和人体-场景接触初始化出发，联合优化相机位姿、多人世界运动和稠密场景；其接触项将人体支撑关系转化为连接场景与运动的显式约束 (Liu et al., 2026)。该路线能够直接

优化几何一致性，但推理开销和对初始化的敏感性促使后续工作将优化结果蒸馏到 JOSH3R 等学习式模型中 (Liu et al., 2026)。在大规模多人场景中，Crowd4D 进一步使用 Human-Scene Interaction Proxy 约束群体尺度和个体世界位置，并通过多阶段优化维持复杂地形上的场景一致性 (Kang et al., 2026)。

另一条路线将人体感知直接注入学习式场景重建。HAMSt3R 在稀疏非标定多视图条件下联合预测 pointmaps、相机和 DensePose/实例语义，再通过独立拟合获得 SMPL 人体 (Rojas et al., 2025)。Human3R 在 CUT3R 上加入 human prompts，使统一模型能够持续读出场景、相机和多个人的世界参数 (Chen et al., 2026)。UniSH 组合场景重建分支、HMR 分支与 AlignNet，由联合特征预测全局场景尺度和逐帧人体平移，并通过 coarse-to-fine 训练改善人体-场景对齐 (Li et al., 2026)。这些方法表明，场景结构先验和人体先验可以在学习式框架中相互补充，但它们主要关注统一读出、联合特征融合或人体放置，没有显式分解人体度量锚定、场景尺度残差和相机尺度传播。

近期工作还开始将人体-场景交互内化为网络的纠正信号。UniCon3R 通过 scene-aware contact prompt 和 contact-guided latent refinement，使预测接触直接影响最终人体表示，而不是仅作为辅助输出 (Sur et al., 2026)。这一路线适合修正与支撑、穿插和接触相关的人体状态。本文处理的是另一组变量：我们不预测接触标签，也不通过场景反馈修改人体姿态或形状，而是从人体表面和环境深度中提取米制残差，并将最终更新严格限制为根部平移。该限制使人物-场景对齐能够直接作用于世界位置，同时避免把局部人体精度的变化混入尺度收益。

2.4 人体引导的米制校准与几何精校

与本文最接近的工作是利用人体几何校准场景尺度，或利用场景几何迭代修正人体。MetricHMSR 首先恢复具有米制形状和全局位置的人体，再把可见人体表面作为稀疏深度锚点；其 human-guided depth refinement 网络为单幅图像预测逐像素 affine fields $s(x), b(x)$ ，从而修正 MapAnything 的初始深度 (Song et al., 2026; Keetha et al., 2025)。这一工作证明了人体可以作为单目米制场景恢复的有效几何参照。本文沿用“人体提供物理尺度”这一基本观察，但面向视频中的相对 VGGT- Ω 重建，将尺度恢复分解为可解释的前表面比值初始化和人物条件 residual affine。我们预测帧级/clip 级仿射而非逐像素 affine field，并将同一个有效尺度同步传播到相机平移，以保持整段视频的世界坐标一致性。

GRAFT 从相反方向研究人体-场景几何精校。它使用 MapAnything、外部单目米制深度和 NLF 初始化场景与人体，通过 24 个 HSI tokens、局部 geometry probes 及迭代 Transformer 预测 pose、shape、translation 和人体尺度的联合更新，将优化式 HSI fitting 摊销为学习式纠正过程 (Pradyumna YM et al., 2026; Sáráandi & Pons-Moll, 2024)。GRAFT 的 geometry-grounded iterative refinement 与本文 TRSTR 的设计联系最紧密，但二者的尺度来源和更新空间不同：GRAFT 先获得外部米制场景，再将人体对齐到该场景；本文首先以米制 SMPL 表面固定相对场景及相机的尺度，随后才在统一米制几何中精校人体。TRSTR 进一步把交互表示扩展为 96 个规范解剖区域，并将更新限制在 translation-only 子空间，保持 NLF 的 pose 和 shape 不变。

UniSH 的 AlignNet 同样联合预测场景尺度与人体平移，而 Crowd4D/JOSH 通过场景支持或接触关系共同约束尺度和世界位置 (Li et al., 2026; Kang et al., 2026; Liu et al., 2026)。与这些联合预测或联合优化路线相比，本文显式保留了解析尺度、学习式 residual affine 和区域平移三者的可辨识职责。这样的分解并不追求另一个 all-in-one 人体-场景读出器，而是隔离并研究一条更具体的几何命题：当场景基础模型只能可靠恢复相对结构时，环境中的人体是否足以建立场景、相机和人体共享的米制尺度，并在不改变局部人体姿态的条件下改善世界坐标重建。

3 方法

3.1 问题定义与整体框架

本文研究从单目 RGB 视频中联合恢复场景几何、相机运动和多个人的运动的问题。该任务的关键并非分别生成视觉上合理的场景和人体，而是消除二者之间未被约束的尺度规范自由度 (scale gauge freedom)：相对场景在任意全局缩放下都可保持投影一致，却会导致相机基线、人体世界轨迹和人物-环境关系失去物理意义。本文以视频中的参数化人体作为内生度量参照，将尺度规范化与人体放置统一为一个由粗到细的几何校准问题，而不重新回归人体局部姿态。

给定长度为 S 的 RGB 序列 $\mathcal{I} = \{\mathbf{I}_t\}_{t=1}^S$ ，场景基础模型 VGGT- Ω 为每一帧输出相对 Z-depth D_t^r 、相机内参 $\mathbf{K}_t$ 、相机外参 $\mathbf{T}_{cw,t} = [\mathbf{R}_{cw,t} \mid \mathbf{t}_{cw,t}]$ ，以及像素对齐的场景特征。这里的 $\mathbf{T}_{cw,t}$ 采用 OpenCV camera-from-world 约定，即 $\mathbf{R}_{cw,t}$ 和 $\mathbf{t}_{cw,t}$ 将世界坐标中的三维点变换到第 t 帧的相机坐标。人体观测器 NLF 在相机坐标中输出第 q 个人的 SMPL 姿态 θ_{tq} 、形状 β_{tq} 、根部平移 τ_{tq} 和检测置信度 c_{tq} 。本文最终输出米制深度 D_t^m 、尺度一致的相机轨迹，以及由相机坐标转换到统一世界坐标的人体网格和关节轨迹。

场景深度和人体观测具有互补的几何属性。VGGT- Ω 从跨帧图像对应关系中恢复稳定的场景结构和相机运动，但其深度只确定到一个未知比例；NLF 输出的 SMPL 网格则受到规范人体模板和人体比例的约束，顶点与关节的位置以米为单位。本文因此不把人体仅视为场景中的动态前景，而是将其视为一种随视频自然出现的度量标杆。只要人体投影与场景深度使用相同的相机内参和图像平面，人体表面的米制 Z-depth 就可以与同一像素处的相对场景深度形成尺度约束。

基于这一观察，本文设计了由粗到细的三步几何校准过程。第一步从可见 SMPL 前表面与相对深度的比值中解析估计粗尺度 s_t^c ，首先消除场景尺度的主要数量级误差。第二步以人体锚点和局部场景特征为条件，预测接近恒等映射的 residual scale ρ_t 与 residual bias b_t ，修正粗尺度残留的系统误差。第三步在已经米制化的场景中运行区域化人体-场景平移精校模块 TRSTR，由多个身体表面区域共同预测人体根部的相机空间平移修正。三个步骤分别解决主尺度、剩余仿射误差和人体全局位置误差，避免单个网络同时承担动态范围差异很大的多个目标。

场景尺度校准与人体平移精校可写为：

$$D_t^m = (s_t^c \rho_t) D_t^r + b_t, \quad (1)$$

$$\tau_{tq}^* = \tau_{tq}^{(0)} + \sum_{k=0}^{K-1} \Delta \tau_{tq}^{(k)}. \quad (2)$$

其中， D_t^m 是最终米制深度， $\tau_{tq}^{(0)}$ 是 NLF 给出的初始人体平移， $\Delta \tau_{tq}^{(k)}$ 是 TRSTR 在第 k 轮预测的增量。式 (1) 中的尺度同时用于场景深度和相机平移，而深度偏置只作用于深度图；式 (2) 只改变人体根部平移，不修改 SMPL 姿态和形状。由此，场景结构、相机运动和人体轨迹通过共享尺度进入同一世界坐标，同时保留人体观测器已经获得的局部姿态精度。

如图 2 所示，GroundedHuman 将推理组织为“观测-尺度校准-空间精校-轨迹稳定”的几何链路。VGGT- Ω 与 NLF 首先从同一组处理后图像中分别提取场景与人体观测，并在共享相机模型下形成可对齐的 metric human-scene evidence；HSI scale calibration 将相对深度转换为米制深度，TRSTR 随后在统一几何中重新探测人体周围的场景并迭代更新人体平移。视频级轨迹稳定步骤不引入独立的未验证训练器，而是对可靠帧和邻帧证据进行 clip-level 聚合，将共享尺度和相机平移保持在同一时间坐标中。第 3.2 节定义两类观测及其坐标关系，第 3.3 节介绍解析尺度，第 3.4 节介绍残差仿射校准，第 3.5 节介绍区域化平移精校，第 3.6 节给出各模块的分阶段训练目标。

3.2 场景与人体观测

本文使用 VGGT- Ω 的场景重建能力作为相对几何基础，而不改变其原有场景推理路径。对于输入序列，VGGT- Ω 的聚合器在跨帧上下文中更新图像 patch tokens、相机 token 和场景 registers。相机头从相机 token 中输出 9 维相机编码，其中包含三维平移、四元数旋转以及水平和垂直视角；这些量被解码为 camera-from-world 外参 $\mathbf{T}_{cw,t}$ 和完整图像内参 $\mathbf{K}_t$ 。稠密预测头从聚合后的 patch features 中恢复每帧相对 Z-depth D_t^r 。本文保留 VGGT- Ω 的相对场景结构和相机旋转，只在后续显式处理缺失的尺度。

人物条件校准同时暴露 VGGT- Ω 的多层场景表示。本文对聚合器最后四个缓存层的 patch features 分别进行线性投影，并在通道维拼接为人体锚点可查询的场景特征图。多层表示将局部外观、深度边界与跨帧结构上下文置于同一特征空间，使后续模块不仅依赖单点深度残差，还能判断该对应是否得到周围场景证据支持。所有场景特征保持冻结，新增学习容量集中在人体条件读出与几何精校模块中。

人体分支采用 NLF 作为外部人体观测器。NLF 直接接收与 VGGT- Ω 相同的缩放、填充后 RGB 张量，而不是再次裁剪到另一套图像坐标。更重要的是，本文将 VGGT- Ω 相机编码解




图 2: GroundedHuman 的整体架构。输入 RGB 序列同时进入场景编码器和人体观测器，形成相对场景、相机、人体以及局部几何探针组成的 metric human-scene evidence。HSI scale calibration 先利用人体前表面恢复粗尺度，再以人物条件残差仿射得到米制深度；TRSTR 在规范人体区域上进行受约束的空间平移精校；最后，视频级轨迹稳定步骤聚合邻帧有效证据并共享尺度，输出尺度一致的 4D 人体-场景世界。

出的 K_t 传入 NLF，使人体恢复、人体投影和场景深度采样共享同一透视相机。对于每个有效人物槽位，NLF 输出 SMPL 轴角姿态、10 维形状参数、相机空间根部平移和置信度；本文同时将轴角姿态转换为连续的 6D 旋转表示，供后续 HSI token 编码使用。

给定人物参数，SMPL 层在人体局部坐标中解码顶点和关节，再加上根部平移得到相机空间人体。第 i 个顶点写为：

$$\mathbf{X}_{tqi}^h = \text{SMPL}_i(\theta_{tq}, \beta_{tq}) + \tau_{tq}. \quad (3)$$

式 (3) 中的 $\mathbf{X}_{tqi}^h$ 与 τ_{tq} 均以米为单位，并位于第 t 帧相机坐标。本文统一采用相机 Z-depth 约定，因此人体锚点使用其 Z 分量与 D_t^r 建立同射线尺度约束；同一约定贯穿解析尺度、深度反投影与 TRSTR 区域探测。

两类观测由此形成互补的几何分解：VGGT- Ω 提供高覆盖率的相对场景，NLF/SMPL 提供低覆盖率但具有物理单位的人体表面。本文在冻结两类预训练先验的条件下显式建立它们的尺度联系，使局部人体估计、场景结构和新增校准模块保持解耦，并允许尺度恢复与平移精校被独立训练和验证。

3.3 人体锚定的解析粗尺度

本文首先将单目尺度恢复分解为解析规范化与学习式残差估计。前者利用 SMPL 表面的米制 Z-depth 消除相对场景的主尺度规范自由度，后者只建模规范化后仍未被解释的偏差。该分解把跨场景的大范围绝对尺度回归转化为以单位尺度为中心的局部校准，并为后续学习模块提供显式、无参数且不依赖测试真实深度的几何初始化。

具体而言，本文从置信人体的 SMPL 网格中按固定步长稀疏采样表面顶点，并使用 $\mathbf{K}_t$ 将相机空间顶点投影到 VGGT- Ω 深度平面。对于顶点 $\mathbf{X}_{tqi}^h = (x_{tqi}^h, y_{tqi}^h, z_{tqi}^h)$ ，其二维投影 $\mathbf{p}_{tqi}$ 以及对应尺度候选值 a_{tqi} 为：

$$\mathbf{p}_{tqi} = \pi(\mathbf{K}_t, \mathbf{X}_{tqi}^h), \quad a_{tqi} = \frac{z_{tqi}^h}{D_t^r(\lfloor \mathbf{p}_{tqi} \rfloor)}. \quad (4)$$

式 (4) 把每个可见人体表面点转化为一个独立的尺度假设。与依赖单一根节点或头部深度的尺度锚定不同，表面共识在人体投影区域内形成过约束估计，使局部关节偏差或单点深度噪声无法直接决定全局尺度。

为使尺度假设与相机可见性一致，本文对投影人体执行离散 **z-buffer** 式前表面筛选：同一像素仅保留最小 **Z-depth** 的人体顶点，并剔除图外、非正深度、无效场景深度及超出尺度支持域的对应。该可见性一致的锚点集合记为 $\mathcal{A}_t$ ，其构造避免被遮挡表面对同一场景像素施加相互矛盾的尺度约束。

本文对 $\mathcal{A}_t$ 上的尺度假设执行鲁棒位置估计，得到帧级解析粗尺度：

$$s_t^c = \text{median}_{(q,i) \in \mathcal{A}_t} a_{tqi}, \quad D_t^c = s_t^c D_t^r. \quad (5)$$

中位数聚合抑制深度边界和错误投影产生的重尾比值；仅估计乘性尺度则把这一阶段严格限制为相似尺度规范化。多人物帧中的有效表面共享同一个 $\mathcal{A}_t$ ，因而共同约束场景尺度，而不是为每个人建立彼此不一致的局部度量坐标。

对于人体严重截断或有效支持不足的帧，本文不接受低置信度帧级估计，而从片段内可靠帧集合 $\mathcal{V}$ 传播鲁棒尺度：

$$s_t^c \leftarrow \exp\left(\text{median}_{u \in \mathcal{V}} \log s_u^c\right). \quad (6)$$

该片段级 **log-median** 在乘性空间中保持对称，并抑制孤立帧的尺度异常；其统计量完全来自视频内部的人体-深度对应，不引入测试集真实尺度。

解析粗尺度的目的并非一次性解决所有深度误差，而是可靠地消除最主要的全局比例。人体初始化误差、人体与深度边界的局部错位以及相对深度中的加性偏差，仍可能使 D_t^c 与真实米制深度存在系统差异。第 3.4 节因此在粗尺度之后引入学习式残差仿射，使网络专注于更窄、更稳定的校准范围。

3.4 人物条件的残差仿射校准

解析中位数只使用了人体和场景在对应像素上的 **Z-depth** 比值，没有显式判断每个局部对应是否可靠，也无法表达相对深度中的剩余偏置。本文进一步设计人物条件的残差仿射模块，将 **SMPL** 人体参数、局部几何探测和 **VGGT- Ω** 场景特征组织为紧凑的人体-场景交互表示。该模块不重新生成稠密深度，而是只预测作用于粗深度 D_t^c 的 **residual scale** ρ_t 和 **residual bias** b_t ，从而保持解析尺度与学习修正之间清晰的职责边界。

3.4.1 人体-场景锚点表示

本文为每个人体构造 24 个 **HSI anchor tokens**，这一紧凑表示沿用 **GRAFT** 中用少量身体位置概括人体-场景关系的设计思想，并针对尺度估计进行适配。其中，21 个 **tokens** 对应 **SMPL** 的非根身体关节；左右手分别由相邻腕部/手部关节平均形成一个手部 **anchor**；最后一个全身 **anchor** 由模板表面上通过确定性最远点采样得到的 27 个固定顶点取均值形成。关节 **anchors** 提供不同肢体位置的局部几何约束，手部 **anchors** 补充末端区域，全身 **anchor** 则编码整体人体位置和体型。

每个 **anchor token** 同时包含人体状态和人物-场景关系。人体状态由 24 个关节的 6D 旋转、10 维形状参数和根部平移组成，并广播到每个 **token**；空间状态包括 **anchor** 的相机坐标和归一化二维投影。对于每个 **anchor**，本文还在其投影附近的 9×9 深度窗口中搜索三维距离最近的有效场景点，并计算该场景点的位置、人物-场景三维偏移、欧氏距离、场景法线和 **Z-depth residual**。若局部窗口没有有效候选，则退回到 **anchor** 投影中心的深度采样。所有属性经共享 **MLP** 投影为 512 维 **HSI tokens**。

该 token 将规范人体先验与观测残差显式因子化：姿态和体型确定 anchor 在米制人体中的语义与位置，局部场景 probe 描述当前场景几何相对该 anchor 的偏差。二者的联合编码使残差 heads 可以在共享人体坐标语义下比较不同部位的尺度证据，而不把绝对尺度线索隐式压缩在单一全局图像特征中。

3.4.2 局部场景注意力

几何 probe 与 VGGT- Ω patch features 分别提供显式三维残差和跨帧视觉-几何上下文。本文将聚合器最后四个缓存层投影并拼接为 512 维场景表示，再围绕每个 anchor 的二维投影抽取 3×3 scene-token 邻域。这种 anchor-conditioned sparse connectivity 将注意力图约束为具有明确投影对应的局部二部图，既保留多层场景证据，又抑制全局注意力在无关动态区域上的信息泄漏。

HSI Transformer 由 5 个共享结构的层组成，每层包含人体 tokens 间的 self-attention、anchor 与其局部场景窗口之间的 constrained cross-attention，以及前馈网络。self-attention 允许分布在不同肢体上的尺度观测相互校验，例如一个受遮挡的手部可以从躯干和下肢的稳定观测中获得上下文；cross-attention 则严格限制第 k 个身体 token 只读取与自身投影相邻的场景 tokens，维持明确的二维-三维对应。隐藏维度为 512，每层使用 8 个注意力头；当前配置对整套 5 层 Transformer 重复执行 3 次，以逐步整合人体内部和局部场景证据。

3.4.3 多人残差仿射

完成交互后，24 个 tokens 在人体内部平均池化，得到每个人的场景校准表示。两个独立的 MLP heads 分别输出 residual log-scale $\Delta \ell_{tq}$ 和 residual bias Δb_{tq} 。由于一帧中不同人物的可见性和检测可靠性不同，本文不直接平均人物预测，而是根据非负人体置信度构造权重：

$$w_{tq} = \frac{\max(c_{tq}, 0)}{\max\left(\sum_j \max(c_{tj}, 0), \epsilon\right)}. \quad (7)$$

人物预测首先在 log-scale 空间聚合。聚合后的 log-scale 被限制在配置给定的区间 $[\ell_{\min}, \ell_{\max}]$ ，随后通过指数映射为正尺度；bias 则在线性空间聚合：

$$\ell_t = \text{clip}\left(\sum_q w_{tq} \Delta \ell_{tq}, \ell_{\min}, \ell_{\max}\right), \quad \rho_t = \exp(\ell_t), \quad b_t = \sum_q w_{tq} \Delta b_{tq}. \quad (8)$$

因此，帧级米制深度为：

$$D_t^m = \rho_t D_t^c + b_t = (s_t^c \rho_t) D_t^r + b_t. \quad (9)$$

log-domain 聚合直接作用于乘性尺度规范，并通过有界映射抑制单个人物的极端预测。无有效人物时，聚合保持恒等残差 $\rho_t = 1, b_t = 0$ ，从而使学习模块不会在缺失人体证据时任意改变解析结果。

3.4.4 视频级尺度一致性与轨迹稳定

帧级残差仿射适合分析单帧深度，但世界坐标重建不能允许相邻帧拥有彼此独立的任意尺度，否则静态场景会随时间膨胀或收缩，相机平移也无法组成一致轨迹。图 2 中的 Track Temporal Stabilizer 对应本文的视频级证据组织步骤：它不替换 VGGT- Ω 或 NLF，也不是一个额外宣称单独训练的网络，而是对有效人体帧、邻帧尺度候选和相机运动证据进行稳健聚合。对于世界坐标任务，本文先组合解析粗尺度与 residual scale，再对整段视频使用共享仿射：

$$\tilde{s}_t = s_t^c \rho_t, \quad s^{\text{clip}} = \exp\left(\text{median}_t \log \tilde{s}_t\right), \quad b^{\text{clip}} = \text{median}_t b_t. \quad (10)$$

式 (10) 在组合后的有效尺度上建立 clip-level gauge，而不是分别平滑解析项和残差项。该操作保留二者的耦合关系，并抑制个别帧人体观测异常造成的尺度跳变；邻帧有效性筛选和轨迹级聚合则避免短时遮挡将单帧异常直接传递到世界轨迹。最终深度与相机外参为：




图 3: 人体尺度桥接与区域平移精校。(a) 投影到相对深度图的人体前表面首先给出解析粗尺度, 24 个 HSI anchors 随后利用局部场景特征预测 residual scale 与 bias。(b) TRSTR 将人体表面划分为确定性区域, 通过多尺度人物-环境探测、门控和不确定性加权的区域投票, 迭代修正人体平移; 姿态和形状保持不变。

$$D_t^m = s^{\text{clip}} D_t^r + b^{\text{clip}}, \quad \mathbf{T}_{cw,t}^m = [\mathbf{R}_{cw,t} \mid s^{\text{clip}} \mathbf{t}_{cw,t}]. \quad (11)$$

为保持投影几何一致, 只有相似变换分量 s^{clip} 作用于相机平移; 仿射偏置 b^{clip} 被限制在深度域, 相机旋转保持不变。由此, 相对相机轨迹与深度场共享同一个米制 gauge, 并为相机空间人体到世界坐标的变换提供一致基准。

3.5 区域化平移精校

完成场景尺度校准后, 剩余误差主要表现为人体根部沿相机射线和切平面方向的错位, 并直接传播到世界坐标关节误差与根部轨迹。本文据此将精校限制在 translation-only 子空间: TRSTR 从多个人体表面区域提取场景一致性证据, 并将其聚合为单一根部平移增量; θ 与 β 被视为局部人体不变量, 在整个精校过程中保持固定。

3.5.1 确定性人体区域

TRSTR 以与 SMPL 运动学一致的解剖表面基作为局部交互载体。每个模板顶点首先依据 dominant LBS joint 被分配到 head/neck、torso、pelvis、upper limbs、hands、lower limbs 或 feet, 随后在各解剖域内执行确定性最远点采样, 形成总计 96 个非均匀表面区域。与图像依赖的动态聚类不同, 该划分在规范模板上一次构造, 并随 SMPL 形变传播到任意身份与姿态, 从而为跨帧、跨人物共享的区域表示提供稳定解剖对应。

对于每个区域, 变形后成员顶点的质心定义其交互中心, 8 个固定成员顶点构成稀疏表面支撑。质心决定区域投影和相机射线基底, 代表点集合编码该区域在当前姿态下的投影范围与三维扩展。区域身份固定而几何状态随人体形变更新, 使 TRSTR 同时获得规范语义和姿态相关的局部表面几何。

该规范-变形双重表示使区域 token 对人物身份和网格顶点密度保持稳定，同时对姿态、尺度和当前平移保持几何敏感。因而，区域可靠性可以在共享解剖语义上学习，而 probe 位置仍随每轮人体状态更新，不依赖预定义接触标签或静态二维裁块。

3.5.2 多尺度人物-场景探测

TRSTR 为每个区域构造多支持域几何探针。区域质心和代表点被投影到米制深度图，代表点相对质心的最大投影扩展决定自适应半径；在此基础上并行采集固定 3×3 、固定 7×7 、自适应区域和外围 annulus。四种支持域分别刻画中心对应、局部容差、姿态相关覆盖与区域外环境，使局部证据在投影尺度变化和初始错位下仍具有可比较的空间语义。

多人场景中的局部深度并非二元的人体/环境观测。本文将全部有效 SMPL 表面光栅化为带实例所有权的深度缓冲，并将每个采样点分解为 self-surface、other-human 和 environment 三类。self-surface 与 environment 分别形成独立 probe 通道；other-human 不参与环境聚合，只以干扰比例进入区域状态。实例感知的证据分解阻止相邻人物被解释为当前人体的支撑或碰撞表面，使区域交互在拥挤与相互遮挡条件下保持人物特异性。

每个采样点由相对区域质心的三维位移、Z-depth residual、归一化像素位移、径向位置、相对代表性表面与实例深度缓冲的残差以及类别标志共同编码。point encoder 和 masked attention pooling 随后在每一种“支持域 $\times$ 证据通道”内聚合点级状态，得到 8 个 probe tokens 及其有效支持率。该表示保留残差的方向、尺度和来源，使后续区域推理能够区分几何不一致与单纯的观测缺失。

区域质心、表面扩展、二维投影、probe tokens、支持率、other-human 占比、自适应半径和 32 维解剖组嵌入共同定义区域状态，并被映射为 256 维隐藏表示。由此，TRSTR 在固定数量的区域 tokens 上联合建模人体-场景残差、局部可见性与实例干扰，而不是把稠密深度裁块压缩为缺少来源信息的黑箱特征。

3.5.3 射线约束的区域投票

TRSTR 将人体平移建模为相机诱导的各向异性误差，而非全局 XYZ 中的同质回归。对于第 k 轮中区域 r 的中心，本文构造单位相机射线 $\mathbf{e}_{\parallel}$ 及其正交切平面基 $\mathbf{e}_x, \mathbf{e}_y$ ，并在该视角协变基底中预测三个有界系数：

$$\mathbf{v}_{tqr}^{(k)} = \delta_{\parallel, tqr}^{(k)} \mathbf{e}_{\parallel, tqr}^{(k)} + \delta_{x, tqr}^{(k)} \mathbf{e}_{x, tqr}^{(k)} + \delta_{y, tqr}^{(k)} \mathbf{e}_{y, tqr}^{(k)}, \quad (12)$$

其中 $|\delta_{\parallel}| \leq d_{\parallel}$, $|\delta_x|, |\delta_y| \leq d_{\perp}$ 。

$\mathbf{v}_{tqr}^{(k)}$ 是区域对共享人体平移的候选 vote， $d_{\parallel}$ 与 $d_{\perp}$ 分别定义纵深和切向信赖域。该参数化将网络输出绑定到成像几何，使不同相机视角下的更新保持一致方向语义，并允许对纵深与横向误差施加不同先验范围。

3.5.4 不确定性加权的人体更新

局部 probe 在遮挡、图像边界和深度缺失下呈现显著异方差性。TRSTR 因此为每个区域联合预测候选 vote、region gate $g_{tqr}^{(k)}$ 与 log-variance $\ell_{tqr}^{(k)}$ 。令 $m_{tqr}^{(k)}$ 表示由有效支持、人物有效性和正深度共同确定的观测掩码，则区域精度权重为：

$$\alpha_{tqr}^{(k)} = m_{tqr}^{(k)} g_{tqr}^{(k)} \exp\left(-\ell_{tqr}^{(k)}\right). \quad (13)$$

有效区域以可学习门控和逆方差联合加权，形成对局部证据质量自适应的稳健聚合：

$$\hat{\mathbf{v}}_{tq}^{(k)} = \frac{\sum_r \alpha_{tqr}^{(k)} \mathbf{v}_{tqr}^{(k)}}{\max\left(\sum_r \alpha_{tqr}^{(k)}, \varepsilon\right)}. \quad (14)$$

区域聚合之后，模块再从所有有效区域隐藏表示中得到人物级表示，并预测 person gate。最终更新先在相机 XYZ 坐标中逐分量限幅，再乘人物级门控：

$$\Delta \tau_{tq}^{(k)} = g_{tq}^{\text{person},(k)} \text{clip}_{\text{component}} \left(\hat{\mathbf{v}}_{tq}^{(k)}, -d_{\max}, d_{\max} \right), \quad (15)$$

$$\tau_{tq}^{(k+1)} = \tau_{tq}^{(k)} + \Delta \tau_{tq}^{(k)}. \quad (16)$$

$\text{clip}_{\text{component}}$ 将人物级更新限制在预定义信赖域；它与区域层的 ray/tangent 边界共同形成分层有界更新。配合 region gate、异方差权重和 person gate，该机制使局部异常证据不能无约束地放大为全身位移。

TRSTR 采用共享权重执行两轮几何闭环。每轮更新 τ_{tq} 后，模块在固定 θ_{tq}, β_{tq} 下重新解码人体表面、更新区域几何，并从新的投影位置重新采集场景 probe。由此，第二轮面对的是第一轮变换后的真实残差分布，而非对同一静态特征重复回归；当前模型仅启用这一空间闭环，不引入时序状态。

3.6 分阶段训练目标

场景尺度校准和人体平移精校具有不同的输出空间与误差分布，本文将二者分阶段训练，而不是端到端联合优化全部系统。尺度模块学习全局仿射参数，需要覆盖相对深度中较大的尺度变化；TRSTR 学习米制三维平移，需要同时处理正确初始化、小幅偏差和严重错位。分阶段训练使每个模块面对与其推理职责一致的监督信号，并允许 VGGT- Ω 、NLF 和已训练前级在后续阶段保持冻结。

3.6.1 残差尺度训练

尺度模块首先在 BEDLAM 的米制深度和 GT SMPL 上进行 residual-gauge 预训练。本文对整段 GT depth 施加共享 lognormal 扰动，在保持序列内部结构不变的同时随机化全局尺度规范，并以扰动的逆变换作为监督。训练仅更新 residual scale 和 bias heads；VGGT- Ω 、相机/深度 heads、HSI backbone 与人体参数全部冻结，使新增 heads 专门学习由人体-场景对应恢复尺度规范。

随后，本文使用与真实推理链更接近的 coarse-residual stratified 状态继续微调尺度 heads。训练首先对 GT depth 采样跨度较大的绝对尺度扰动，生成模拟的无尺度深度；再使用第 3.3 节的解析算法从可见 GT SMPL 表面估计 coarse scale。为覆盖人体初始化、投影和局部深度误差造成的粗尺度不确定性，训练进一步对解析结果施加由 identity、near、medium 和 hard 四类组成的分层扰动。最终 residual target 是绝对恢复尺度与实际使用粗尺度之比，即网络只需预测粗尺度没有解释的剩余比例。

尺度 teacher 同样来自可见人体表面。将 GT SMPL 顶点投影到训练深度后，本文在局部窗口内选择与人体 Z-depth 一致的可见场景点，并计算人体深度与输入深度的比例。每个人体必须具有足够的可见点，帧级尺度候选还经过基于 median absolute deviation 的鲁棒过滤。对剩余尺度候选取中位数得到 ρ_t^* 。当前训练不使用非零 bias teacher，因此 bias 由零目标约束，避免模型在纯尺度可以解释误差时滥用加性偏置。

尺度阶段的总目标为：

$$\mathcal{L}_{\text{scale}} = \lambda_s \mathcal{L}_{\log\text{-scale}} + \lambda_b \mathcal{L}_{\text{bias}} + \lambda_d \mathcal{L}_{\text{depth}}. \quad (17)$$

其中， $\mathcal{L}_{\log\text{-scale}}$ 在 $\log \rho_t$ 与 $\log \rho_t^*$ 之间计算 Smooth-L1 损失， $\mathcal{L}_{\text{bias}}$ 约束加性自由度， $\mathcal{L}_{\text{depth}}$ 则在有效米制像素上监督 $\rho_t D_t^c + b_t$ 。参数域与几何域的联合监督分别约束仿射分解和最终深度，避免尺度与偏置之间出现等价但不可泛化的补偿。

3.6.2 TRSTR 训练

完成尺度模块训练后，本文冻结全部前级，只优化 TRSTR 的区域特征、vote、region gate、log-variance 和 person gate。训练输入使用 GT metric depth 和 GT SMPL 构造，并将状态划分为 clean、scale-error、NLF-like translation-error 和 mixed-error 四类。scale-error 对场景深度与目标人体位置施加一致的小幅尺度变化；NLF-like error 在相机 ray/tangent 基底中注入不同强度的根部平移噪声；mixed-error 同时包含两类误差。由此，TRSTR 既学习在尺度变化后重新对齐人体，也学习修正上游人体观测器常见的纵深与横向偏移。

对于每轮迭代，监督目标不是要求每个区域一次输出完整剩余位移，而是将当前状态到目标平移的剩余量按剩余迭代数分配，形成 **staged remaining vote target**。只有有效区域的 **vote** 参与区域监督，**region gate** 则以区域有效掩码为目标进行二元交叉熵训练。人物级最终平移使用 Smooth-L1 损失直接对齐目标，从而同时约束局部区域提议和聚合后的全身结果。

TRSTR 总损失写为：

$$\begin{aligned} \mathcal{L}_{\text{TRSTR}} = & \lambda_{\text{vote}} \mathcal{L}_{\text{vote}} + \lambda_{\text{trans}} \mathcal{L}_{\text{trans}} + \lambda_{\text{gate}} \mathcal{L}_{\text{gate}} + \lambda_{\text{reg}} \mathcal{L}_{\text{reg}} \\ & + \lambda_{\text{strong}} \mathcal{L}_{\text{strong}} + \lambda_{\text{id}} \mathcal{L}_{\text{identity}} + \lambda_{\text{safe}} \mathcal{L}_{\text{no-worse}} + \lambda_{\text{mono}} \mathcal{L}_{\text{monotonic}}. \end{aligned} \quad (18)$$

其中， $\mathcal{L}_{\text{vote}}$ 监督有效区域的分阶段平移提议， $\mathcal{L}_{\text{trans}}$ 监督最终人物平移， $\mathcal{L}_{\text{gate}}$ 学习区域有效性， $\mathcal{L}_{\text{reg}}$ 约束更新幅度。为同时保持大误差修正能力与局部恒等性，本文进一步引入四个状态选择性目标： $\mathcal{L}_{\text{strong}}$ 强化远离目标状态的恢复， $\mathcal{L}_{\text{identity}}$ 约束 **clean** 状态的零映射， $\mathcal{L}_{\text{no-worse}}$ 惩罚相对初始化的退化， $\mathcal{L}_{\text{monotonic}}$ 约束迭代误差不增长。它们使优化目标从平均回归扩展为对初始误差状态敏感的安全精校。

训练阶段以 GT 几何和可控扰动定义尺度与平移的修正轨迹；推理阶段仅使用 VGGT- Ω 相对场景、NLF 人体观测及本文预测的校准量，不访问 GT **depth**、**camera** 或 **SMPL**。尺度 **heads** 与 TRSTR 分别优化并顺序执行，VGGT- Ω 和 NLF 保持冻结，从而形成一个模块化的尺度规范化与平移精校框架。

4 实验

我们围绕三个相互关联的问题评估本文方法：人物的局部姿态与形状是否得到保持，人体提供的尺度约束能否改善世界坐标中的运动恢复，以及这种尺度约束能否将 VGGT- Ω 的无尺度深度转换为与人物与环境一致的度量重建。为此，我们在 3DPW 上评估局部人体网格，在 EMDB-2 上评估全局人体运动，并在 TUM-Dynamic 和 Bonn 上分别评估相机轨迹与人体中心视频深度。这些任务从人体质量、世界轨迹、相机稳定性和场景尺度四个方面验证同一套人物-场景重建系统。

本文采用 VGGT- Ω -1B-512 预测场景深度和相机，并在人体相关任务中使用 NLF 提供人体观测。除特别说明外，对比数值取自 Human3R、UniSH、MetricHMSR、UniCon3R 和 DuoMo 的公开结果；完整训练配置与网络超参数见附录。

为直观展示 GroundedHuman 的时序输出，图 4 给出了三个代表性视频片段。每一行从左到右依次展示输入帧、在统一世界坐标中累积的米制场景与按时间编码的人体网格，以及人体和相机的世界轨迹。中间的场景点云与人体网格使用同一尺度和坐标规范，右侧曲线则用于显示轨迹随时间的连续变化；该图是定性可视化，不将轨迹曲线作为额外定量指标。三个片段覆盖高动态姿态、户外行走/蹲姿和运动场景，用于检验人体-场景关系在视角变化、局部遮挡和长时序下是否保持连贯。

4.1 局部人体网格恢复

我们首先在 3DPW 上评估相机坐标中的人体姿态和形状。遵循 Human3R 的协议，使用 PA-MPJPE、MPJPE 和 PVE 作为评价指标。PA-MPJPE 衡量消除刚性变换和尺度后的姿态结构；MPJPE 和 PVE 分别衡量关节和网格顶点误差。表 1 同时保留 EMDB-1 列，以便与 Human3R 的局部人体评测形式一致。

本文取得 37.3 mm PA-MPJPE、60.3 mm MPJPE 和 71.4 mm PVE。由于系统直接保留冻结人体观测器给出的姿态和形状，后续尺度校准与 TRSTR 仅处理场景尺度和人体根部平移，因此该结果验证了全局几何校正不会损害局部人体网格。

相对于 Human3R，本文将 PA-MPJPE、MPJPE 和 PVE 分别降低 15.4%、15.3% 和 15.9%。这一结果表明，以可靠的人体姿态作为度量锚点，可以将模型能力集中于场景尺度与全局位置校准，同时完整保留局部人体质量，并为后续世界坐标重建提供稳定的身体尺度参照。

4.2 世界坐标全局人体运动

我们在 EMDB-2 上评估世界坐标中的人体运动与根部轨迹。遵循 Human3R 和 UniSH 的协议，将长序列划分为至多 100 帧的片段。WA-MPJPE 使用整个片段估计对齐变换，反映片段




图 4: 时序人体-场景重建结果。每行从左到右依次为输入视频帧、累积的米制场景与按时间编码的人体网格, 以及世界坐标中的人体、相机轨迹。所有帧在同一尺度和坐标规范下联合可视化; 右侧曲线用于展示轨迹连续性与准确性。

表 1: 3DPW 和 EMDB-1 上的局部人体网格恢复。“✓”表示不需要对应输入; 所有误差单位为 mm, 越低越好。

Method	Crop-free	Detection-free	Intrinsic-free	3DPW (14)			EMDB-1 (24)		
				PA-MPJPE ↓	MPJPE ↓	PVE ↓	PA-MPJPE ↓	MPJPE ↓	PVE ↓
CLIFF	×	×	×	43.0	69.0	81.2	68.3	103.3	123.7
HMR2.0	×	×	✓	44.4	69.8	82.2	61.5	97.8	120.0
ReFit	×	×	×	—	—	—	58.6	88.0	104.5
TokenHMR	×	×	✓	44.3	71.0	84.6	55.6	91.7	109.4
CameraHMR	×	×	✓	38.5	62.1	72.9	43.7	73.0	85.4
BEV	✓	✓	✓	46.9	78.5	92.3	70.9	112.2	133.4
Multi-HMR	✓	✓	×	45.9	73.1	87.1	50.1	81.6	95.7
Human3R	✓	✓	✓	44.1	71.2	84.9	48.5	73.9	86.0
Ours	×	×	✓	37.3	60.3	71.4	—	—	—

内运动的整体准确性; W-MPJPE 仅使用前两帧进行对齐, 对后续尺度漂移和轨迹累积误差更敏感; RTE 衡量刚性对齐后的根部轨迹误差。表 2 同时列出 RICH 结果, 以区分动态相机和不同场景条件下的性能。

本文在 EMDB-2 上取得 58.468 mm WA-MPJPE、149.959 mm W-MPJPE 和 1.079% RTE。相对于 JOSH, 三项误差分别降低 15.1%、14.2% 和 17.0%; 相对于 Human3R, 分别降低 47.9%、44.0% 和 51.0%; 相对于 UniSH, 分别降低 50.7%、44.5% 和 81.4%。

W-MPJPE 的改善比局部人体指标的变化更能反映本文方法的作用。由于 W-MPJPE 仅在片段起始处对齐, 后续误差直接暴露了尺度和相机运动的累积偏差。本文在保持 NLF 局部人体结果不变的同时, 将 W-MPJPE 降至 149.959 mm, 说明人体尺度标杆主要修正了从相机坐标到世界坐标的几何关系。较低的 WA-MPJPE 和 RTE 进一步表明, 这一收益同时体现在片段内运动结构和完整根部轨迹上。

人体-场景交互。世界坐标轨迹指标衡量全局运动精度, 却不能完整反映人体与近邻环境之间的局部几何关系。遵循 GRAFT 的定性比较方式 (Pradyumna YM et al., 2026), 图 5 在躺卧、倚靠、坐姿和双人场景中进一步比较 UniSH、Human3R 与本文方法。现有方法能够将人体定位到重建场景中, 但在支撑面附近仍会出现悬浮、穿透或前后深度偏移。本文方法将人体与环境置于共享米制坐标, 并利用 TRSTR 的局部几何证据精校根部平移, 使躯干、四肢和

表 2: EMDB-2 和 RICH 上的全局人体运动估计。预处理输入部分的“✓”表示不需要相应外部输入；输出部分的“✓”表示方法支持该能力，“✗”表示不支持或未作为模型输出。关节误差单位为 mm，RTE 单位为%，均为越低越好。

Category	Method	Preprocessed Input (✓ = not required)				Output			EMDB-2 (24)			RICH (24)			
		Tracking	Camera	Depth	Contact	Multi-Person	Metric	Human-Scene	Contact-Aware	WA-MPJPE ↓	W-MPJPE ↓	RTE ↓	WA-MPJPE ↓	W-MPJPE ↓	RTE ↓
Offline	GLAMR	×	×	×	×	✓	×	×	×	280.8	726.6	11.4	129.4	236.2	3.8
	SLAHMR	×	×	×	×	✓	×	×	×	326.9	776.1	10.2	132.2	237.1	6.4
	COIN	×	×	×	×	×	×	×	×	152.8	407.3	3.5	169.5	254.5	—
	GVHMR	×	×	×	×	×	×	×	×	111.0	276.5	2.0	78.8	126.3	2.4
	TRAM	×	×	×	×	×	×	×	×	76.4	222.4	1.4	127.8	238.0	6.0
	JOSH	×	×	×	×	×	×	×	×	68.9	174.7	1.3	89.0	132.5	3.0
	PromptHMR	✓	✓	✓	✓	×	×	×	×	71.0	216.5	1.3	118.2	207.0	5.6
Online	TRACE	✓	✓	✓	✓	✓	×	×	×	529.0	1702.3	17.7	238.1	925.4	610.4
	WHAM	×	×	×	×	×	×	×	×	135.6	354.8	6.0	108.4	196.1	4.5
	JOSH3R	×	×	×	×	×	×	×	×	220.0	661.7	13.1	—	—	—
	Human3R	✓	✓	✓	✓	×	×	×	×	112.2	267.9	2.2	110.0	184.9	3.3
	MetricHMSR	×	×	×	×	×	×	×	×	72.1	199.5	1.4	109.6	165.5	1.9
	UniCon3R	×	×	×	×	×	×	×	×	113.7	285.6	2.3	81.5	129.8	1.7
	UniSH	×	×	×	×	×	×	×	×	118.5	270.1	5.8	118.1	183.2	4.8
	Ours	✓	✓	✓	✓	✓	✓	✓	✓	58.468	149.959	1.079	—	—	—




图 5: 人体-场景几何交互的定性比较。每行从左到右依次为输入图像、UniSH、Human3R 和本文方法的联合人体-场景重建。相较于基线中可见的悬浮、穿透或深度错位，本文方法在保持局部人体姿态和形状的同时，获得了更贴合场景表面的根部位置与更连贯的支撑关系。该图提供几何交互的定性证据；全局运动和度量场景性能分别由表 2 与表 3 定量评估。

座椅或地面之间形成更符合输入观测的支撑关系。尤其在室内沙发和户外长椅示例中，这种改善并未依赖姿态或形状更新，说明受约束的平移精校能够直接提升人物在场景中的几何落位。

4.3 通用三维重建

相机位姿估计。我们首先在 TUM-Dynamic 上评估相机轨迹。遵循 Human3R 的设置，对预测轨迹进行 Sim(3) 对齐并计算绝对轨迹误差 (ATE)。如图 6(a) 所示，VGGT- Ω 在 50、100、150、200、300、400 和 500 个输入视图上的 ATE 分别为 0.00299、0.00434、0.00493、0.00591、0.00634、0.00645 和 0.00692 m。即使输入长度从 50 增加到 500，误差增量仍不足 4 mm，且所有评测点均保持在 7 mm 以下。相比之下，Human3R 的参考曲线从约 0.013 m 增长到 0.052 m。VGGT- Ω 在 500 视图处将 ATE 降低约 86.7%，表明其相机轨迹不会随序列长度产生明显漂移。

视频深度估计。我们随后在 Bonn 上评估人体中心视频深度。表 3 中的本文结果直接在人体尺度校准后的模型输出上计算 Abs Rel 和 $\delta < 1.25$ ，评测时不使用 GT scale 或 shift。该设置衡量的不只是场景的相对结构，还包括跨帧尺度和绝对深度的一致性。

本文得到 0.08599 Abs Rel 和 0.96377 的 $\delta < 1.25$ 。相对于 Human3R，本文在保持相当 Abs Rel 的同时将阈值准确率提高 0.98 个百分点；相对于 CUT3R， $\delta < 1.25$ 提高 2.68 个百分点；与 VGGT 的差距仅为 0.22 个百分点。值得强调的是，这些结果直接由人体标杆校准后的 VGGT- Ω 深度得到，评测过程中不使用 GT scale 或 shift。结果表明，即使场景模型本身不提




图 6: 通用三维重建评测。(a) TUM-Dynamic 上随输入视图数量变化的相机轨迹 ATE; (b-c) Bonn 上随请求输入视图数量变化的 Abs Rel 和 $\delta < 1.25$ 。蓝色 VGGT- Ω ATE 曲线来自本文评测器的精确输出; 相机与深度参考曲线由 Human3R 图 9 近似数字化得到。Bonn 红色曲线为 Pure VGGT + GT scale 的 oracle diagnostic: 每个序列和输入前缀使用一个由 GT 拟合的尺度, 仅用于分析 VGGT- Ω 相对几何的可度量上界, 不属于本文方法的无特权预测结果。横轴表示请求的最大视图数; 较短序列使用其全部可用帧, 不重复补帧。

表 3: Bonn 上的人体中心视频深度估计。Abs Rel 越低越好, $\delta < 1.25$ 越高越好。

方法	Abs Rel ↓	$\delta < 1.25$ ↑
DUST3R	0.151	0.839
MASt3R	0.188	0.765
MonST3R	0.072	0.957
Fast3R	0.194	0.772
MVDUST3R	0.426	0.357
CUT3R	0.078	0.937
Aether	0.273	0.594
FLARE	0.152	0.790
VGGT	0.057	0.966
π^3	0.049	0.975
Human3R	0.086	0.954
UniSH	0.035	0.980
本文方法	0.08599	0.96377

供可靠的绝对尺度, 人体的物理尺寸仍能将大部分场景像素校准到正确深度的 1.25 倍范围内。

图 6(b-c) 进一步给出了 VGGT- Ω 相对深度的 oracle 尺度诊断。在 50 至 500 个请求视图范围内, 使用单个 GT 拟合尺度后, Abs Rel 始终位于 0.045 至 0.062, $\delta < 1.25$ 始终位于 0.957 至 0.974; 在 500 视图处仍达到 0.057 Abs Rel 和 0.958 的阈值准确率。该结果说明 VGGT- Ω 已经恢复了稳定的相对场景结构, 并将绝对尺度识别为关键瓶颈之一。本文使用人体物理尺寸替代 oracle 尺度来源, 并获得 0.96377 的阈值准确率, 从而验证人体能够为无尺度场景几何提供有效的度量参照。

图 7 从物体尺度层面补充了上述像素级评测。对于同一场景, Ground Truth、MapAnything 与本文方法均显示了人体和环境几何之间的长度关系; GroundedHuman 的人物高度和部分环境测量更接近真实值, 并且人体与桌面、隔断等参照物保持在同一米制范围。该现象与 Bonn 上无需 GT scale 或 shift 的深度结果相互印证: 人体锚定不仅提供像素级深度校准, 也使重建结果能够被解释为具有现实长度意义的场景几何。由于遮挡和局部深度噪声仍会影响个别物体, 本文将该图作为定性可视化, 不把单个物体的误差外推为新的 benchmark 指标。

4.4 尺度一致性分析

三组实验形成了一条一致的证据链。首先, 3DPW 中与 NLF 相同的局部人体误差表明, 尺度校准没有通过改变人体姿态或形状换取全局指标。其次, EMDB-2 上领先的 WA-MPJPE、W-MPJPE 和 RTE 说明人物在世界坐标中的运动结构、长时漂移和根部轨迹均得到改善。




图 7: 现实尺寸测量的定性对比。两列分别对应包含人体与典型室内物体的场景，三行依次展示 Ground Truth、MapAnything 和本文方法；红色标注表示由对应几何测得的人体高度或物体长度。GroundedHuman 借助人体的规范物理尺寸，将人体与桌面、隔断和墙体等环境几何置于同一可解释的米制坐标中，所得尺寸整体更接近真实参照。该图用于展示度量关系的可解释性，数值性能仍以 Bonn 深度指标为准。

最后，TUM-Dynamic 上低于 7 mm 的长序列 ATE 独立说明场景骨干具有稳定的相机轨迹；Bonn 的 oracle 诊断进一步将绝对尺度识别为关键瓶颈，而本文 0.96377 的阈值准确率证明这一尺度可以由人体提供。

这些结果共同验证了本文的核心设计：人体首先提供全局尺度标杆，局部人物-场景证据再用于修正人体平移。前者确定人物与环境共享的米制尺度，后者减少人物在场景中的局部错位。由此，本文在保持局部人体质量的同时，获得更准确的世界轨迹、稳定的相机运动和尺度一致的场景深度。

5 结论

本文研究单目视频中场景、相机与人体的尺度一致重建，并验证了一个核心观点：即使场景基础模型只提供稳定的相对几何，具有米制含义的参数化人体仍可作为视频中的内生度量参照。围绕这一观点，我们首先通过可见 SMPL 前表面的尺度共识解析消除场景的主尺度自由度，再利用人物条件 residual affine 修正剩余比例和深度偏置，并将 clip 级共享尺度同步传播到相机平移。随后，TRSTR 以规范解剖区域为局部几何探针，通过门控与不确定性加权的迭代投票只修正人体根部平移，保持姿态和形状不变。3DPW 结果表明局部人体精度得到保持；EMDB-2 上的 58.468 mm WA-MPJPE、149.959 mm W-MPJPE 和 1.079% RTE 验证了尺度一致的世界运动与根部轨迹；Bonn 上无需 GT scale/shift 的 0.08599 Abs Rel 和 0.96377 $\delta < 1.25$ 则说明人体能够把相对场景转换为有效米制深度。结合 TUM-Dynamic 上稳定的长序列相机轨迹，这些结果构成了从局部人体、场景尺度到世界运动的一致证据链。

本文方法的适用性仍取决于上游场景与人体观测的质量。当人体长期不可见、严重截断或整个片段缺少可信人体时，人体尺度锚点会减弱；错误的相对场景结构或 SMPL 形状与平移也会传播到后续校准。TRSTR 被有意限制在 translation-only 子空间，因此不能纠正错误姿态、形状或细粒度接触，当前实现也仅使用空间区域证据。未来可在保持局部 HMR 不变性

的前提下，引入跨帧尺度置信聚合、遮挡下的区域记忆以及受控的人体-场景接触约束，使人体度量锚定扩展到更长、更拥挤和交互更复杂的视频。

致谢

双盲审稿版本中省略。

生成式人工智能使用声明

本工作使用生成式人工智能工具协助中文稿的结构组织、语言编辑和概念图草拟。所有技术设计、代码、实验数据、公式、文献主张与最终内容均由作者审查；作者对本文全部内容负责。

参考文献

- Yue Chen, Xingyu Chen, Yuxuan Xue, Anpei Chen, Yuliang Xiu, and Gerard Pons-Moll. Human3r: Everyone everywhere all at once. In *International Conference on Learning Representations*, 2026. arXiv:2510.06219.
- Hongbo Kang, Tianyi Zhou, Qingyang Yang, Hongwei Wen, Jing Huang, Yu-Kun Lai, and Kun Li. Crowd4d: Scene-aware monocular 4d crowd reconstruction. In *Proceedings of the 43rd International Conference on Machine Learning*, volume 306 of *Proceedings of Machine Learning Research*, 2026.
- Nikhil Keetha, Norman Müller, Johannes Schönberger, Lorenzo Porzi, Yuchen Zhang, Tobias Fischer, Arno Knapitsch, Duncan Zauss, Ethan Weber, Nelson Antunes, et al. Mapanything: Universal feed-forward metric 3d reconstruction. *arXiv preprint arXiv:2509.13414*, 2025.
- Vincent Leroy, Yohann Cabon, and Jérôme Revaud. Grounding image matching in 3d with mast3r. In *European Conference on Computer Vision*, 2024.
- Mengfei Li, Peng Li, Zheng Zhang, Jiahao Lu, Chengfeng Zhao, Wei Xue, Qifeng Liu, Sida Peng, Wenxiao Zhang, Wenhan Luo, Yuan Liu, and Yike Guo. Unish: Unifying scene and human reconstruction in a feed-forward pass. *arXiv preprint arXiv:2601.01222*, 2026.
- Zhizheng Liu, Joe Lin, Wayne Wu, and Bolei Zhou. Joint optimization for 4d human-scene reconstruction in the wild. In *International Conference on Learning Representations*, 2026. arXiv:2501.02158.
- Matthew Loper, Naureen Mahmood, Javier Romero, Gerard Pons-Moll, and Michael J. Black. Smpl: A skinned multi-person linear model. In *Seminal Graphics Papers: Pushing the Boundaries, Volume 2*, pp. 851–866. Association for Computing Machinery, 2023.
- Georgios Pavlakos, Vasileios Choutas, Nima Ghorbani, Timo Bolkart, Ahmed A. A. Osman, Dimitrios Tzionas, and Michael J. Black. Expressive body capture: 3d hands, face, and body from a single image. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 10975–10985, 2019.
- Pradyumna YM, Yuxuan Xue, Yue Chen, Nikita Kister, István Sárándi, and Gerard Pons-Moll. Graft: Geometric refinement and fitting transformer for human scene reconstruction. *arXiv preprint arXiv:2604.19624*, 2026.
- Sara Rojas, Matthieu Armando, Bernard Ghanem, Philippe Weinzaepfel, Vincent Leroy, and Grégory Rogez. Hamst3r: Human-aware multi-view stereo 3d reconstruction. *arXiv preprint arXiv:2508.16433*, 2025.
- István Sárándi and Gerard Pons-Moll. Neural localizer fields for continuous 3d human pose and shape estimation. In *Advances in Neural Information Processing Systems*, 2024.
- Johannes Lutz Schönberger and Jan-Michael Frahm. Structure-from-motion revisited. In *IEEE Conference on Computer Vision and Pattern Recognition*, 2016.

- Zehong Shen, Huaijin Pi, Yan Xia, Zhi Cen, Sida Peng, Zechen Hu, Hujun Bao, Ruizhen Hu, and Xiaowei Zhou. World-grounded human motion recovery via gravity-view coordinates. In *SIG-GRAPH Asia Conference Papers*, 2024.
- Soyong Shin, Juyong Kim, Eni Halilaj, and Michael J. Black. Wham: Reconstructing world-grounded humans with accurate 3d motion. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 2070–2080, 2024.
- Chentao Song, He Zhang, Haolei Yuan, Haozhe Lin, Jianhua Tao, Hongwen Zhang, and Tao Yu. Metrichmsr: Metric human mesh and scene recovery from monocular images. *arXiv preprint arXiv:2506.09919*, 2026.
- Tanuj Sur, Shashank Tripathi, Nikos Athanasiou, Ha Linh Nguyen, Kai Xu, Michael J. Black, and Angela Yao. Unicon3r: Unified contact-aware 4d human-scene reconstruction from monocular video. *arXiv preprint arXiv:2604.19923*, 2026.
- Jianyuan Wang, Minghao Chen, Nikita Karaev, Andrea Vedaldi, Christian Rupprecht, and David Novotny. Vggt: Visual geometry grounded transformer. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025a.
- Jianyuan Wang, Minghao Chen, Shangzhan Zhang, Nikita Karaev, Johannes Schönberger, Patrick Labatut, Piotr Bojanowski, David Novotny, Andrea Vedaldi, and Christian Rupprecht. Vggt- ω . *arXiv preprint arXiv:2605.15195*, 2026a.
- Qianqian Wang, Yifei Zhang, Aleksander Holynski, Alexei A. Efros, and Angjoo Kanazawa. Continuous 3d perception model with persistent state. *arXiv preprint*, 2025b.
- Shuzhe Wang, Vincent Leroy, Yohann Cabon, Boris Chidlovskii, and Jérôme Revaud. Dust3r: Geometric 3d vision made easy. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024a.
- Yifan Wang, Jianjun Zhou, Haoyi Zhu, Wenzheng Chang, Yang Zhou, Zizun Li, Junyi Chen, Jiangmiao Pang, Chunhua Shen, and Tong He. π^3 : Permutation-equivariant visual geometry learning. *arXiv preprint arXiv:2507.13347*, 2025c.
- Yufu Wang, Ziyun Wang, Lingjie Liu, and Kostas Daniilidis. Tram: Global trajectory and motion of 3d humans from in-the-wild videos. In *European Conference on Computer Vision*, pp. 467–487, 2024b.
- Yufu Wang, Evonne Ng, Soyong Shin, Rawal Khirodkar, Yuan Dong, Zhaoen Su, Jinhyung Park, Kris Kitani, Alexander Richard, Fabian Prada, and Michael Zollhöfer. Duomo: Dual motion diffusion for world-space human reconstruction. *arXiv preprint arXiv:2603.03265*, 2026b.
- Ye Yuan, Umar Iqbal, Pavlo Molchanov, Kris Kitani, and Jan Kautz. Glamr: Global occlusion-aware human mesh recovery with dynamic cameras. In *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 11038–11049, 2022.
- Junyi Zhang, Charles Herrmann, Junhwa Hur, Varun Jampani, Trevor Darrell, Forrester Cole, Deqing Sun, and Ming-Hsuan Yang. Monst3r: A simple approach for estimating geometry in the presence of motion. *arXiv preprint arXiv:2410.03825*, 2024.