专利技术交底书

（涉及单目人体运动捕捉、环境交互和三维重建）

客户名称	徐英博			
发明名称	一种融合人体尺度校准与分层环境交互的单目人体运动捕捉方法			
技术联系人	徐英博	邮　箱	xinbev@126.com	
手　　机	13644073786		专利类型	☑ 发明 ☐ 实用新型
固定电话	待填写			

温馨提示：

1、为了能使专利代理人很好的理解技术从而撰写出质量更高的专利申请文件，请对背景技术和技术方案进行全面、清楚的描述。

2、全文对同一事物的叫法应统一，避免出现一种事物多种名称。

3、英文缩写请提供英文全称及中文译文。

项目：单目动捕与环境交互

一、所属技术领域

本发明属于计算机视觉、三维人体运动捕捉和三维场景重建领域，具体涉及从单目视频恢复人体运动与周围环境几何，并利用环境交互信息校正人体在世界坐标中的位置的方法。

二、背景技术

单目人体运动捕捉通常从视频估计人体姿态、形状和根位置；场景重建网络则估计相对深度及相机运动。两类结果可以组合输出人体和环境，但相对场景深度与人体度量尺度未必一致，初始人体位置也可能偏离真实的地面或物体表面。现有前馈式方法如 Human3R、UniSH 和 SHOW 同时重建人体与场景，仍需要处理尺度和人景对齐问题；UniCon3R 利用人体—环境接触信息改善重建；另有方法在推理时联合优化人体、场景及相机。

仅用人体与场景的单帧深度比值定尺度时，遮挡、人体初始位置误差及场景深度误差会混入尺度估计；逐帧独立估计还可能产生尺度波动。直接用整幅场景特征修正人体位置时，人体表面、支撑环境和其他人物的证据易混杂，悬浮及穿透仍可能出现。显式接触识别或测试时优化需要额外处理。

以上现有技术的出处可供代理人检索核验：Chen 等，Human3R: Everyone Everywhere All at

Once，arXiv:2510.06219，2025；Li 等，UniSH: Unifying Scene and Human Reconstruction in a Feed-Forward Pass，arXiv:2601.01222，2026；Shi 等，Scene and Human in One World: Reconstruction in a Feedforward Pass，arXiv:2606.27720，2026；Sur 等，UniCon3R: Unified Contact-aware 4D Human-Scene Reconstruction from Monocular Video，arXiv:2604.19923，2026。

三、本发明创造要解决的技术问题

本发明要解决的技术问题是：如何在只输入单目视频的条件下，使人体、场景和相机轨迹处于同一度量尺度，并根据人体与环境的空间关系修正人体根位置，减少人体悬浮和穿透，同时避免在推理时对全部人体、场景和相机变量进行联合优化。

其中，“环境交互”是指以人体表面锚点和区域为查询，检索对应场景几何及视觉特征，利用检索得到的关系预测尺度和位置校正；不以显式接触标签作为必要输入。

四、本发明创造的技术方案

本发明采用“人体锚定的度量标定—分层环境交互定位”两阶段方案。输入为单目 RGB 视频，输出为共享度量世界坐标中的人体网格及运动轨迹、场景三维点和相机轨迹。实施方式如下：

步骤 S1，获取基础观测。利用场景估计器得到每帧相对深度、相机内外参和多层视觉特征；利用人体估计器得到每人的参数化人体姿态、形状、初始根平移、可见人体表面及估计置信度。一个实施例使用冻结的 VGGT-Ω 和 NLF 分别提供上述观测；只要其他估计器提供等效观测，也可替换。

步骤 S2，建立初始度量对应。用相机内参将可见人体表面点投影到相对深度图，筛除无效、越界、非正深度和被更近人体表面遮挡的样本；同一像素只保留最近的可见人体表面。对有效人体—场景对应，计算同一相机射线上的人体深度与场景相对深度之比，以中位数估计帧初始尺度。

$$s_t^c = median_{(q,i)\in A_t} \frac{[V_{tqi}^c]_z}{D_t^r(\pi(K_t, V_{tqi}^c))}$$

$$D_t^{coarse} = s_t^c D_t^r$$

若某帧没有有效对应，则不使用该帧进行序列标定；若整段均没有有效对应，则返回单位尺度并标记“标定无效”，不把该回退结果视为有效度量估计。

步骤 S3，利用人体锚点校准度量。沿人体表面选取锚点，编码人体状态、锚点位置与投影、局部场景几何、法向及深度残差；先对锚点执行自注意力，再以锚点查询其投影邻域的多层场景特征。聚合后由两个预测头输出残余对数尺度和深度加性偏置。具体实施例中每人使用 24 个锚点及 3×3 邻域；这些数量为实施例参数。

$$s_{tq} = s_t^c \, exp(\Delta log \, s_{tq})$$

步骤 S4，进行多人、多帧稳定化。按照人体置信度融合各人的结果，并在有效帧之间对对数尺度作稳健聚合，得到整段视频共享尺度及偏置。尺度同时作用于相对场景深度和相机平移；偏置只作用于深度，相机旋转与内参保持不变。用校准深度及内参反投影得到度量场景点。

$$D_t^m = sD_t^r + b$$

$$t_{cw,t}^m = st_{cw,t}^r$$

步骤 S5，构造分层环境交互特征。将人体表面划分为对应区域，每个区域由质心和表面采样顶点描述。以区域投影为中心，读取小固定窗口、大固定窗口、随区域投影范围变化的自适应窗口及外围环带的场景证据；具体实施例采用 96 个区域、每区质心加 8 个顶点、3×3 及 7×7 固定窗口。

依据当前人体的实例深度缓冲区，将与本人可见表面深度一致的样本放入“本人表面”通道，将有效但不属于本人的场景样本放入“环境”通道；其他人物样本作为干扰特征处理，不混入上述两通道。无效采样通过掩码排除，空支持返回零特征及零有效比例。

步骤 S6，预测并聚合人体位置校正。每个区域依据交互特征预测沿视线方向和两个正交方向的三维位移系数、门控及对数方差，形成区域根平移建议。区域权重由有效性、门控和预测不确定度共同确定，加权聚合后由人员级门控控制是否施加校正。

$$\alpha_r = m_r g_r exp(-\ell_r)$$

$$\hat{v} = \frac{\Sigma_r \alpha_r v_r}{max(\Sigma_r \alpha_r, \varepsilon)}$$

将聚合位移按坐标分量截断在预设范围内，再更新人体根位置。更新后重新投影人体、重新确定实例归属并重建区域查询，以免沿用更新前的环境特征。一个实施例进行两次共享参数的前馈更新，期间人体姿态、形状、场景几何和相机参数保持固定。

$$\tau^{(k+1)} = \tau^{(k)} + g_p \, clip(\hat{v}, -\delta_{max}, \delta_{max})$$

步骤 S7，输出世界坐标结果。利用校准后的相机外参，将度量场景点和已修正根位置的人体网格变换到同一世界坐标系，得到人体运动、相机轨迹和场景三维结构。

$$x_w = R^T(x_c - t)$$

训练实施例：冻结场景和人体基础估计器，仅训练度量标定与环境交互定位模块。首先利用带度量深度及人体标注的数据和合成深度尺度扰动训练尺度、偏置及深度误差；再扰动真实人体根平移和场景尺度，以区域位移、最终根位置、门控和更新幅度为监督，同时约束正确输入保持原位、错误输入得到恢复。V3 论文实施例先使用 BEDLAM，再使用 EMDB 与 3DPW 数据继续训练。推理阶段不依赖上述训练数据、显式接触标签或多变量测试时联合优化。

五、本发明创造的效果和优点

1. 人体可见表面提供初始度量参照，锚点与局部环境特征预测残余尺度和深度偏置；多人、多帧置信聚合使场景深度与相机平移使用同一共享尺度，有助于降低单帧估计误差和尺度波动。

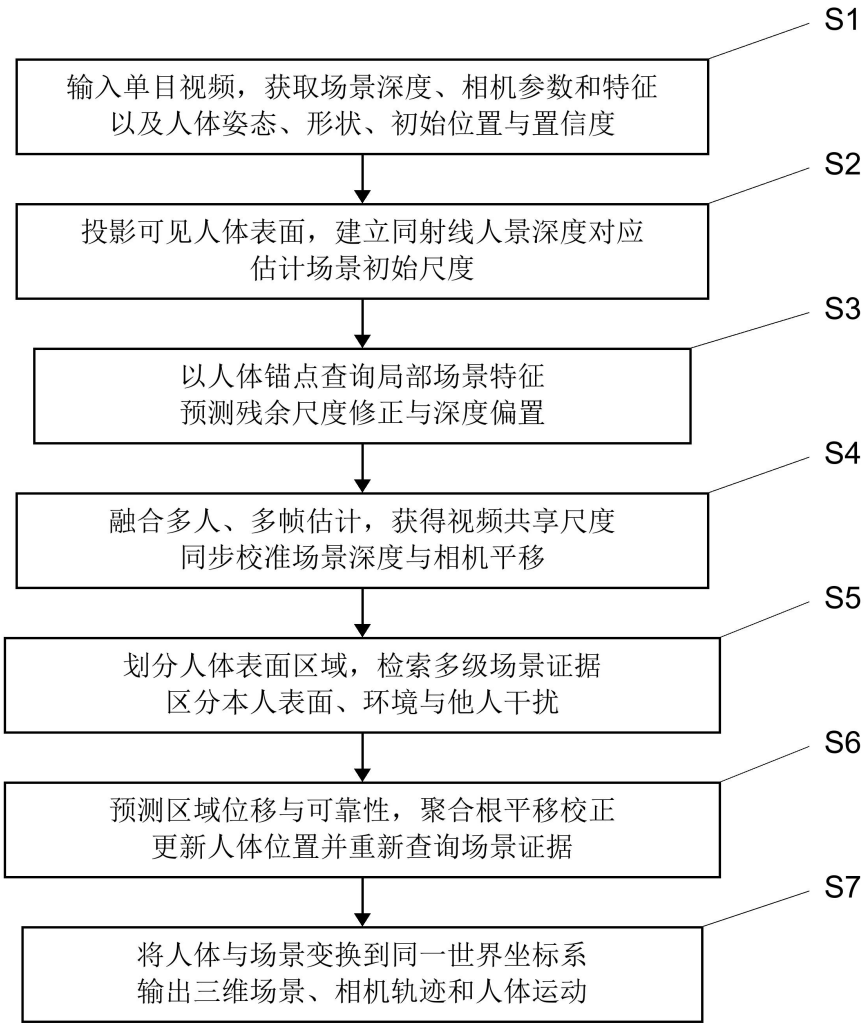
2. 人体区域在多个空间范围内检索本人表面及周围环境，并排除其他人物干扰；按有效性、门控与不确定度聚合位移，位置改变后重新检索环境证据，有助于减轻悬浮和穿透。

3. 冻结基础估计器并使用有限次前馈修正，可保留已有的人体姿态和场景重建结果，减少推理时联合优化处理。

效果证据边界：V3 论文稿的 RICH 消融实验在保持度量标定的条件下，关闭交互定位时碰撞帧比例为 12.83%，完整方法为 6.48%。此为论文稿特定评估设置的结果，申请前应由发明人核对原始实验记录和统计口径。

六、附图及附图的简单说明

图 1　本发明单目动捕与环境交互方法流程图。图中 S1 至 S7 分别对应获取观测、人体—场景初始尺度、锚点校准、时序聚合、分层环境查询、根位置校正与世界坐标输出。



图中框、箭头与编号表示步骤及其先后关系。实施例中的锚点数、区域数、窗口尺寸和更新次数可以依据输入分辨率、人体可见性和计算资源调整。